

경력

Polyfact | AI Software Engineer

2024.08 ~ 2025.09 · 파리

프랑스 의회 생중계와 문서를 다루는 로펌·로비 회사의 일을 자동화하는 B2B 플랫폼. 인턴 합류 후 곧 시니어 이탈 상황에서, CEO로부터 제품, 백엔드, AI 파이프라인, SvelteKit 프론트엔드 인수. 이후 들어온 엔지니어 및 인턴의 코드 리뷰 및 교육 전담.

Python · FastAPI · TypeScript · SvelteKit · Supabase/Postgres · Turbopuffer · OpenAI · Deepgram · LangChain/LangGraph/LangSmith · GCP

- **정치 데이터 RAG 파이프라인**: 소스마다 watermark cron으로 새것만 가져와 메타데이터를 통일하고 긴 문서는 300~500 단어로 겹치게 잘라 저장. 정확해야 하는 값은 Postgres, 임베딩은 vector DB에 두고 벡터와 BM25를 rank fusion으로 합치되 기관·연도 namespace 및 metadata 기반 사전 1차 선별. Pinecone으로 시작해 수정안 챗은 Turbopuffer로 이관(French BM25 tokenizer, filter 4KB 제한이라 본문 제외). 고객 관심 프로필도 임베딩하여 의미 기반 매칭.
- **수정안 페이지**: 법안당 수백 건의 수정안이 발생하는 구조. 법안별 목록과 검색, 필터를 만들고 사용자가 들어오면 서버가 AI 백엔드에 법안을 넘겨 수정안마다 리포트를 미리 생성해 저장. 사용자가 직접 쓴 리포트를 우선하고, export는 저장된 리포트를 Word로 내보내되 생성 중이면 끝날 때까지 대기. 마지막엔 로비스트가 훑는 방식에 맞춰 엑셀처럼 보는 UI로 재설계 및 구축.
- **라이브 의회 워크스페이스**: 하원·상원·EU 의회 동시 다중 라이브 생중계 대응. 라이브 영상과 AI 챗터, Deepgram 실시간 transcript, 챗과 메모장을 한 화면에 두고, 화자를 실시간 인식해 정치인 프로필과 연결하고 문장 하이라이트와 자동 스크롤, 문장 클릭과 영상 이동을 상호 연동 구현. 세그먼트 누락 경고 누적으로 인한 경고 누적으로 플레이어가 죽는 문제를 막기 위해, hls.js 권장 복구 위에 30초 감쇠 카운터와 404 차단 로직 적용.
- **라이브 context 주입과 수정안 실시간 매칭**: 회의 중 질의에 최신 이벤트와 고객사 메모리 기준으로 답하는 체계 수립. transcript와 현재 화자, 논의 중인 수정안에 고객사 정보와 memory를 더해 context를 모으는 pipeline 설계, 구현 및 팀 내 전파. Eliasse의 실시간 수정안 상태도 transcript 시점 연동, 해당 백엔드를 Deno KV 및 Queue 기반 아키텍처로 재설계하여 동시성 제어(CAS Lock)와 단일 라우팅 구현, 실시간 이벤트 중복 처리 방지 및 트래픽 부하 최적화.
- **AI 백엔드와 마이그레이션**: 서비스 확장성을 고려해 빈 저장소부터 공통 AI 백엔드 및 모듈형 파이프라인을 설계·구축하여, 이후 팀 내 추가된 모든 AI 기능이 동일 플랫폼 위에서 신속하게 배포 및 운영될 수 있도록 기반 마련. 요청당 token 비용 기록, I/O 병목을 Non-blocking Async 구조로 전환하여 동시 요청 처리 성능 개선. 문서 질문은 중복 호출 제거와 병렬 처리, token 예산 재조정에 streaming과 캐시를 더해 10~15초에서 2초 안쪽으로 단축. FastAPI를 Deno로, 흩어진 저장소를 모노레포로, 다시 Node로 옮기며 두 버전을 나란히 띄워 무중단 전환.
- **Observability 구축 및 팀 개발 기준 수립**: 공용 Logger를 설계해 호출부 코드 수정 없이 4개 서비스의 로그를 Sentry로 집계하여 기존 수동 제보 의존 문제 해결. OpenTelemetry 기반 구간별 Latency 프로파일링 및 PostHog 활용 트래픽·사용 패턴 분석 체계 구축. 생중계 중 발생한 Transcript 지연 이슈(Chunking 병목) 당일 원인 규명 및 수정. Deno Deploy의 OTel 미지원 제약 분석 후 Sentry 범위 확장 및 신규 워크로드 GCP 이관, 이를 기반으로 Node.js 마이그레이션 기술 의사결정 주도. RFC 7807 표준 에러 규격, Observability 가이드, AI 도구용 Rules 파일 수립 및 팀 내 전파.
- **LangChain, LangGraph, LangSmith 도입**: LangChain, LangGraph, LangSmith를 챗과 리포트 agent에 도입하여 운영, 새 모델과 API는 우리 서비스 출력으로 검증한 뒤 보통 며칠 안에 반영. 웹 검색은 당시 OpenAI API로 출체가 나오지 않아 Tavily 연동.

6개월 인턴 후 계속 근무 제안을 받아 이어서 근무. CEO 추천서(2024.12): "top 1%" in conscientiousness, "I would bet on him."

Belage | Freelance Full-Stack Engineer

2025.10 ~ 2026.09 · 파리

다수 브랜드를 운영하는 사진 스튜디오의 기존 수동 업무 프로세스(구글 폼 예약, 수작업 정산) 전면 자동화.

Next.js · TypeScript · Supabase/Postgres (RLS, PL/pgSQL, pg_cron) · SumUp (online + card-present) · Google Calendar API · Vercel · pgTAP

- **브랜드별 고객 사이트**: 브랜드마다 도메인을 두고 한 코드베이스에서 배포. 카테고리별 포트폴리오, 패키지화 날짜 선택부터 참고 사진 업로드와 결제까지 이어지는 예약 과정, 후기와 별점, 사진 리뷰, 6개 언어 다국어 지원.
- **단일 schema와 결제 정합성**: 모든 브랜드의 고객 사이트와 백오피스(스케줄, 직원 권한, 인보이스)를 schema 하나로 운영. 예약과 결제 상태 전이, 인보이스는 RLS와 server-side role check 뒤 단일 트랜잭션 PL/pgSQL RPC로 돌려 불완전 결제 및 데이터 정합성 오류 방지. 온라인과 매장 결제는 하나의 atomic settlement path에 provider 재조회 idempotent webhook, 놓친 결제를 잡는 reconciliation cron, 정산 확인 후 credit note 발행.
- **인보이스와 상담 자동화**: 프랑스 법정 facture/avoir 번호(CGI art. 242 nonies A)를 atomic counter와 DB constraint로 보장하고 정산 시 PDF 발송, 국세청 현금영수증 내역 export. 상담은 네 채널에서 단계별 자동 메시지로, 사진작가별 Google Calendar 양방향 동기화 구현.

추가 경력 (직접 만들고 운영하는 제품)

Bonjour Admin | AI Software Engineer & Founder

2026.02 ~ 현재 · 유료 구독자

개인별 체류 상황이 다른 환경에서 범용 챗봇의 한계를 극복하고, 프랑스 법령 및 공식 안내만 근거로 정확한 조항 기준 답변을 제공하는 AI 서비스 개발. Polyfact에서 만들던 RAG 파이프라인을 더 최신 구성으로 설계. 서비스 구축과 운영, 수익화까지 혼자 수행.

Next.js 16 / React 19 · TypeScript · Supabase + pgvector · OpenAI Responses API · Cohere rerank · Upstash Redis · Polar.sh · PostHog · Vercel

- **Personalised retrieval**: 같은 질문도 사람마다 답이 달라서, 프로필(국적, 지역, 체류 자격, 가족, 직업)이 tag와 RRF boost로 retrieval을 조정하고 적용할 법 체계 선정. 사용자가 외국인 체류 포털 데이터를 연결하면 reverse-engineering으로 매핑한 110개 이상 endpoint 기준으로 파싱.
- **공식 소스만 근거로**: Légifrance 법전 6개는 매일, 정부 소스 15개는 매주 다시 수집하고, 웹 검색은 55개 도메인 whitelist 안에서만, 법정 수치는 버전 관리해 ground truth로 활용.

- **근거가 약할 때를 아는 retrieval:** retrieval gate → semantic cache → full-text와 dual embedding(pgvector) weighted RRF → Cohere rerank → quality gate 순으로 검증하고, 근거 부족 시 검색 결과 기각 후 agent tool 기반 공식 소스 재조회. 답은 함수 10개를 쓰는 tool-calling 3라운드로 만들고 병렬 verifier 3개(CRAG, 법령 존재, citation entailment)로 검증. LLM이 쓴 SQL은 공개 fact 테이블 4개만 읽는 anonymous role로 실행.
- **Cost Telemetry 기반 Latency 및 비용 최적화:** stage별 cost telemetry 분석 결과 verification이 비용의 80%, web pre-search가 법률 답변 latency의 49% 차지. pre-search를 stale일 때만 실행해 검색 18초에서 0.9초로 단축, follow-up 질문에서는 retrieval gate가 검색의 60~70% 우회.
- **법령 개정에 대응하는 CI 기반 Eval 파이프라인:** 100건 이상 eval set과 LLM-as-judge 지표 6개를 만들고, judge 점수를 교차 확인하려고 모델 없이 계산하는 deterministic metrics 병행 구축. 법령 수치 케이스는 정답을 버전 관리되는 facts 테이블에서 실행 시점에 읽어 법이 바뀌어도 테스트 코드 수정 불필요. 매주 CI에서 돌고 회귀 발생 시 CI 빌드 실패 처리.

SonnanAI | AI Software Engineer

2026.01 ~ 현재 · 파리

매주 현장에서 수작업으로 진행되던 한-불 동시통역을 자동화하여, 통역사 없이 실시간 자막과 음성을 제공하는 파이프라인 구축.

Python · Flask (SSE) · Silero VAD · OpenAI transcribe + local Whisper · Qwen2.5-7B LoRA · Ollama · pytest

- **고가용성라이브 스트리밍 파이프라인:** 불안정한 현장 네트워크 및 외부 API 장애 환경에서도 중단 없는 서비스를 위한 결함 허용 3단 Fallback 아키텍처 설계. VAD로 발화 분할 후 Cloud STT 장애 시 Local Whisper로 자동 전환, 번역 3단 레이어 (Cache → Local LoRA → Cloud) 구축. 8초 Latency 제한 준수를 위한 Request Hedging 및 Circuit Breaker 적용, 오프라인 전용 경로 구축.
- **자체 corpus LoRA와 실측 guard:** 3년치 한불 설교 아카이브를 정규화, 문장 정렬해 약 8K 쌍을 만들어 Qwen2.5-7B LoRA로 학습하고 Ollama로 로컬 서빙. 라이브 세션마다 재학습 쌍이 쌓이는 distillation flywheel 구축 및 train/eval 분리. STT가 무음에서 지어내는 문장은 실제 라이브 음성 데이터에서 잔 logprob 분포로 차단(발화 -0.12 이상, 환각 -1.3 미만), 사전 번역 cache 활용으로 발화의 약 18% 흡수/절감.

학력

École 42 Paris | IT Architecture Expert, RNCP 7 (석사 수준)

2023.10 ~ 2026.10 · 파리

Data and database architecture 전공. 강의도 교수도 없이 프로젝트와 동료 평가로만 28개 과제 수행. 외부 라이브러리 없이 밑바닥부터 구현하고 검증.

- **numpy-only MLP:** backpropagation을 손으로 유도해 구현하고 Adam 및 L2 규제를 적용한 뒤, 직접 짰 gradient를 수치 미분과 대조하는 gradient check로 검증(최대 오차 1.72e-10). 정확도 96%인데 test BCE가 0.33이던 원인은 어려운 샘플을 확신하며 틀리는 과신이라, mini-batch와 L2, early stopping으로 0.0499(정확도 98.59%).
- **EEG brain-computer interface:** 뇌파에서 어느 쪽 손을 움직이려 했는지 읽는 과제. CSP를 두 클래스 공분산의 generalised eigenvalue problem으로, 고유값 분해는 Jacobi 회전으로 직접 짜 SciPy 결과와 1e-15까지 일치. CSP를 fold 밖에서 학습해 점수가 1.0까지 부풀던 누수는 fold마다 다시 학습하게 고쳐 0.844로 교정.
- **CNN 앞 병행 분류기 (PyTorch):** conv block 4개로 직접 설계. 첫 학습의 validation 100% 원인 분석 결과, 데이터 증강 후 분할로 인한 Train/Val 데이터 누수 확인 및 교정. 먼저 나누고 학습 중에만 증강해 held-out 99.79%, fine-tuned EfficientNet-B0(99.86%)와 동등한 수준.
- **x86 kernel 직접 구현 (C, NASM):** libc 없이 recursive page directory 기반 higher-half paging, Multiboot memory map 기반 frame allocator, kmalloc/vmalloc heap. paging을 켜는 순간에도 코드는 저메모리에서 돌아 bootstrap page directory에 identity와 higher-half를 함께 매핑했고, 디버거도 stdout도 없어 QEMU monitor로 VGA 메모리를 덤프해 출력 검증.
- **Rust 오목 엔진:** Negamax에 null-move pruning, transposition table, Lazy SMP를 엮어 한 수 500ms 안에 depth 10~17. 게임 로그에서 탐색이 depth 4로 무너진 국면을 회귀 테스트로 고정하고 원인을 하나씩 분리 및 디버깅 완료.

École 42 Seoul

2021.03 ~ 2023.05 · 서울

- **42 해커톤 대상 (과학기술정보통신부 장관상):** 3인 팀을 이끌고 순수 C로 BMP 이미지를 다루는 교육용 과제를 과제 명세와 reference implementation, autograder까지 한 세트로 설계했고, 42 Amsterdam, Brussels, Paris 캠퍼스 발표 진행.
- **C++98로 만든 미니 nginx:** nginx 문법 설정 파일을 읽어 가상 호스트와 location을 구성하고 kqueue 논블로킹 이벤트 루프 하나로 static file, 업로드, CGI를 처리하는 HTTP/1.1 서버. 설정 파서와 서버 메인 로직을 맡아 잘못된 설정을 로딩 시점에 걸러내고 server에서 location으로 설정 상속 구조 구현.
- **멀티플레이어 Pong 웹 게임 (NestJS + React):** 42 OAuth와 2FA 로그인, socket.io 실시간 채팅(채널과 DM, 차단), 랭킹과 업적까지 붙인 실시간 대전 Pong. 42 학생들이 실제로 들어와 썼고, 채팅과 친구 도메인을 맡아 소켓 이벤트와 화면 상태 단방향 데이터 흐름으로 정리.
- 그 외: Q-learning snake, linear/logistic regression, seed로 동기화되는 멀티플레이어 테트리스, K3s-ArgoCD GitOps, OWASP Top 10 실습, Flutter 앱 8개, libc, bash subset shell, raycasting 엔진, STL container.

기술

- **Open source:** CUBRID (2021): 스토리지 엔진의 Double Write Buffer 병목을 프로파일링해 최적화 패치를 upstream에 기여, 코어 팀에 발표.
- **Proficient:** TypeScript, Python, C/C++, SQL (PostgreSQL) | Experienced with: Rust, Deno, Solidity, Dart/Flutter, x86 assembly
- **AI systems:** RAG (hybrid retrieval, RRF, rerank), agentic tool loops, CRAG, LLM-as-judge evals, cost/latency engineering, LoRA fine-tuning, Ollama, VAD/STT/TTS
- **Backend & Web:** Next.js, FastAPI, Flask, SvelteKit, Node/Deno, Supabase/Postgres (RLS, PL/pgSQL), Redis, SSE/WebSocket | Infra: GCP Cloud Run, Vercel, Docker, K3s + ArgoCD, GitHub Actions, Sentry, OpenTelemetry, PostHog
- **언어·병역:** 한국어(모국어) · 영어(업무) · 프랑스어(기초) · 군필(육군 헌병, 2019.01 ~ 2020.08)